

2026/03/10 書報討論演講報告：

智慧魚缸及口罩檢驗管理系統

演講者：國立臺中科技大學資訊與流通學院院長 陳永隆教授

1. 演講背景與學術脈絡分析

從資訊工程研究的深層視角審視，演講內容精準捕捉了當前 AIoT 領域的核心戰略：將物聯網（IoT）系統整合、電腦視覺（Computer Vision）瑕疵檢測以及深度學習模型優化結合為一套完整的技術鏈。對於研究者而言，這不僅是技術的羅列，更是探討如何將物理世界的感知數據，透過穩健的演算法轉化為高價值的決策資訊。

演講內容歸納出三大核心技術主軸：

- **智慧感測與物聯網架構**：聚焦於 ESP32 控制器與標準化通訊協定的整合，解決實體環境數據採集的穩定性問題。
- **卷積神經網路（CNN）的影像分類應用**：深入探討影像預處理（Image Preprocessing）在受控環境（如工業品管）中對提升分類精度與模型收斂的關鍵影響。
- **YOLO 系列模型在遙感影像偵測的架構演進**：針對高解析度、小目標且背景複雜的遙感影像，進行模型結構輕量化與特徵提取能力的深度優化。

這些技術共同建構起現代化智慧監控與決策系統。從基礎感知的數據採集，到針對特定任務的模型微調與優化，展示了 AI 技術從實驗室走向真實應用場景的完整工程實踐路徑。

2. 智慧魚缸：物聯網系統架構與自動化控制實踐

在現代生活快節奏的背景下，利用遠端操控制造穩定的生態環境不僅是生活便利的提升，更是對動態平衡系統自動化控制的技術挑戰。建立一個能自主調節、即時回饋並支援跨平台操作的「智慧魚缸」系統，涉及了感測器校準、異質協定通訊以及智慧識別等多重考量。

2-1. 系統架構與技術選擇

該系統展現了層次分明的 IoT 設計邏輯，其技術選型充分考量了擴展性與效能平衡：

- **硬體層 (Hardware)**：以 ESP32 作為核心處理節點，負責邊緣端的傳感器數據處理與執行器控制。
- **軟體與管理層 (Software)**：整合 Home Assistant 作為中控平台，利用 ESPHome 進行韌體開發，並透過 HomeKit 實現直覺式的行動終端操作。
- **傳輸協議 (Protocol)**：採用 MQTT 輕量級訊息傳輸協定，確保感測數據與控制指令在低頻寬環境下仍具備高度即時性。

2-2. 關鍵感測器功能機制

針對魚缸生態環境的維護，系統設計了三項關鍵監控機制：

感測器類型	運作機制	對生態環境維護的影響
溫度感測	實時監測水溫，低於臨界值即觸發自動化邏輯開啟加熱棒。	防止水溫劇烈波動造成的魚隻生理壓力或死亡。
混濁度感測	監測水質潔淨指標，低於標準時發送提醒或啟動換水程序。	確保水質穩定，有效抑制病菌增生風險。
光度感測	偵測環境照度，根據日夜光照強度自動控制 LED 燈光。	提供穩定的光合作用條件，模擬自然晝夜規律。

2-3. 影像辨識與環境參數協作

系統利用 Python 結合 OpenCV 模組，特別針對鬥魚 (Betta fish) 等特定物種進行辨識。影像辨識不僅用於監控，更與環境參數連動：系統可根據識別出的魚種活動狀態或特定物種需求，自動調整餵食頻率、燈光亮度或水流強度，實現了「感知與行為耦合」的高階智慧化運作。

從基礎的 IoT 環境感知轉向深層的模型精度優化，是資訊工程從「互聯」邁向「智慧」的技術演進過程。接下來，我們將探討如何透過深度學習架構優化來解決工業級的瑕疵檢測問題。

3. 瑕疵檢測系統：影像預處理與深度學習模型之性能評估

在工業品質控制領域，CNN 架構已成為自動化檢測的標準。本次演講針對「口罩檢驗管理系統」進行了深度剖析，探討如何精確識別包括：裁切瑕疵、邊緣斷裂、掛繩斷裂、邊緣過長、沒有掛繩、正常口罩等六大類別。

3.1. 實驗環境設定

為確保實驗的嚴謹性與可重複性，研究採用了高效能的硬體平台進行模型訓練與推理測試：

- **CPU:** Intel XEON E5 2699v3
- **RAM:** 64GB DDR4 3200MHz
- **GPU:** NVIDIA GeForce RTX 3060 12GB
- **OS:** Windows 10 Enterprise

3.2. 影像預處理 (IP) 的核心作用

演講中提出的三種方法 (IP-ResNet152V2, IP-InceptionV3, IP-Xception) 皆強調了影像預處理 (Image Preprocessing, IP) 長寬比修正。研究證實，透過 IP 處理能確保口罩特徵在進入模型時不產生形變，進而顯著提升模型在訓練初期的收斂效率與最終預測精度。

3.3. 實驗數據與折衷 (Trade-off) 分析

在性能評估中，IP-Xception 展現了最優的綜合表現。根據數據紀錄，IP-Xception 在訓練 60 回合後，準確率從基準 (無預處理) 的 96.38% 成功提升至 98.21%。分析模型間的 Trade-off：雖然 ResNet152V2 深度最深且參數量最大 (約 58M)，但 IP-Xception (參數僅 21M) 在保持高精度的同時，推理執行時間僅需 0.047s，相較於 ResNet152V2 的 0.055s 具備更好的執行效率，非常適合應用於產線的即時偵測。

3.4. 技術細節摘錄

「本研究基於 Keras 框架，採用 Categorical Crossentropy 作為損失函數。優化器學習率 (Learning Rate) 設定為極其精確的 0.0001，旨在確保模型在處理六類細微瑕疵特徵時能穩定收斂，避免跳過局部最佳解。」

當視覺任務從受控背景下的分類，轉向如遙感影像等背景雜亂、物件尺度極小的偵測任務時，架構設計需從單純的深層分類轉向具備區域感知的偵測優化。

4. 遙感影像物件偵測：YOLOv8n 架構的深度優化分析

遙感影像在智慧交通、環境監測及軍事行動中具備極高價值，但也面臨目標物微小且解析度挑戰極大的痛點。

4.1 YOLOv8n 的深度優化策略

演講針對 YOLOv8n 提出了三項核心結構改進：

- **Bi-directional Feature Pyramid Network (Bi):** 在 Neck 層加入雙向特徵融合路徑，並引入加權特徵融合 (Weighted Feature Fusion) 機制，使不同尺度的特徵能更有效地交流。
- **Transformer 區塊 (TF):** 此改進為提升效能的關鍵。透過將 Backbone

最後一個 C2f 模組替換為 Transformer 區塊，不僅利用自注意力機制強化了模型的全區域理解能力，更因為 Transformer 在特定配置下能減少重複的捲積運算，從而實現了**模型減參增效**的效益。

- **Coordinate Attention (CA)**：透過**嵌入位置資訊**，CA 模組使模型能將注意力精準集中於特徵圖中感興趣的小目標物上，有效解決了遙感影像中目標物密集且尺度微小的偵測難題。

4.2 RSOD 資料集實驗結果分析

下表展示了優化模組在遙感影像資料集（RSOD）上的表現對比：

模型架構	mAP@0.5 (%)	參數量 (Parameter)	推理時間 (Inference Time)
YOLOv8n	90.2%	3.01M	3.0ms
YOLOv8n-Bi	91.7%	3.02M	3.2ms
YOLOv8n-TFBi	92.4%	2.86M	3.5ms
YOLOv8n-TFBiCA	94.5%	2.88M	4.0ms

4.3 系統性思考與效能分析

從數據可見，YOLOv8n-TFBiCA 在參數量僅 2.88M（低於原始模型）的情況下，將 mAP@0.5 從 90.2% 提升至 94.5%。雖然推理時間從 3.0ms 略增至 4.0ms，但在遙感監控場景中，這種極微小的推理延遲換取 4.3% 的精度提升是非常值得的折衷。這證明了結構優化（特別是 Transformer 的引入）能有效剔除模型冗餘，同時強化特徵捕捉能力。

這些從模型優化中獲取的經驗，將成為未來開發高效能邊緣 AI 應用的核心資產。

5. 總結與研究啟發

站在資工研究員的立場，本次演講完美演示了從「系統架構設計（IoT 感知層）」到「演算法效能壓榨（CNN/YOLO 處理層）」的完整學術與工程閉環。

針對未來的研究路徑，我認為有以下關鍵延伸方向：

1. **AI 預測維護模型**：在智慧魚缸等應用中，下一步應結合雲端大數據，開發水質變化的預測模型，實現在病菌增生或溶氧量下降前進行提前干預，而非僅止於事後報警。

2. **跨領域 AI 整合價值：**物聯網提供數據廣度，電腦視覺提供數據深度。未來的研究應更致力於 IoT + AI + Computer Vision 的跨技術高度整合，這將是解決真實世界複雜問題（如遠端智慧醫療、大規模工業自動巡檢）的必經路徑。

本次報告不僅學習到模型參數的調優，更體會到結構性創新對提升系統整體價值的核心意義。