

2026/03/31 書報討論演講報告：

如何打造台版 Edge Impulse TinyML 開發平台

演講者：歐尼克斯實境互動工作室創辦人 許哲豪博士

1. 前言：演講背景與邊緣人工智慧的戰略價值

在生成式 AI (GenAI) 帶動全球算力需求激增的背景下，演講深入探討了 AI 技術如何「從雲端走向邊緣」。對於資訊工程與嵌入式系統的研究生而言，這不僅是硬體規格的縮減，更是運算範式的戰略轉向：將 AI 推論能力下放至極低功耗的嵌入式感測節點 (TinyML)，已成為實現物聯網智慧化不可或缺的關鍵。

本次演講的核心目標可歸納如下：

- 平台標竿分析：以國際領先的 TinyML 開發平台 Edge Impulse 為參考對象。
- 台灣戰略自主：探討如何結合台灣半導體產業鏈優勢，建立具備在地化支援能力的 TinyML 開發平台。
- 全鏈路生態整合：從底層神經處理單元 (NPU) 硬體、自動化工具鏈到產業應用端，建構完整的邊緣智慧開發體系。

本報告將從技術範式轉移、硬體架構演進、工具鏈自動化及台灣產業戰略地位四個維度，進行深度剖析與技術洞察。

2. 技術範式轉移：邊緣智慧 (Edge AI) vs. 生成智慧 (GenAI)

當前人工智慧的演進呈現「極大化」與「極小化」的雙極化趨勢，兩者在資源配置與設計哲學上有顯著差異：

比較維度	邊緣智慧 (Edge AI / TinyML)	生成智慧 (Generative AI)
資源消耗	極少資源 (Flash/RAM 極度受限)	無限資源 (雲端機房、海量儲存與頻寬)
運算目標	模型極小化 (Ultra-small model)	模型極大化 (Ultra-large model)

供電模式	電池供電、追求超低功耗	電網供電、高能耗消耗
連網需求	廣義定義：不上網即能完成所有推論 狹義定義：電池供電的獨立 Endpoint Device	需保持連線以存取雲端算力

邊緣智慧的核心在於「智慧感測」。神經網路技術已從處理影像的 CNN 與處理時序信號的 RNN，進化至 Transformer 架構。更具前瞻性的觀察是 AI 代理的演進：

- **AI Agent (單一代理)**：具備單一任務的作業能力 (Single worker)。
- **Agentic AI (整合代理)**：轉向多代理協作模式 (Team working together)。對於資源受限的邊緣環境，未來的挑戰在於如何透過高效的多代理編排 (Multi-agent orchestration)，在低算力 MCU 上實現複雜的環境感知與群體決策。

3. 硬體算力與加速晶片的演進層次

在邊緣運算領域，「算力牆」直接決定了應用的落腳點，算力需求與應用類別呈現明確的階層化：

- **MOPS (智慧感測)**：喚醒詞識別、運動感測、異常振動偵測。
- **GOPS (電腦視覺)**：影像分類、物件偵測、姿態估測。
- **1 TOPS (自然語言)**：語音轉文字、意圖分析。
- **10 TOPS (生成式對話)**：翻譯、摘要生成、文字生圖。
- **100 TOPS (多模態應用)**：即時語言翻譯、跨媒體決策分析。

3.1. 硬體加速核心邏輯

神經網路運算的本質是大量的矩陣運算 ($Y = AX + B$)。為了加速此核心線性代數運算，各類硬體透過專屬的乘加運算單元 (MAC) 實現效能提升：

1. **CPU**：透過提升工作時脈與單指令週期硬體指令進行通用加速。
2. **DSP**：專注於多乘加飽和運算，適合數位訊號處理。
3. **NPU**：專為神經網路設計的硬體加速器，效能與能耗比最優。

3.2. NPU 規格分層與性能指標

在 TinyML 實作中，Arm Ethos 系列 NPU 的導入至關重要。需區分其應用分層：

- **Ethos-U55**：鎖定低功耗應用，如 ALIF、Nuvoton (新唐) M55M1、Himax

(奇景) WE2。

- **Ethos-U65**：針對高效能嵌入式系統，如 NXP i.MX93。
- **Ethos-U85**：鎖定高階邊緣應用，如 ALIF E8。值得注意的是，新唐 M55M1 系列透過 Cortex-M55 結合 Ethos-U55，已能提供高達 110 GOP (Giga Operations) 的 CNN/DNN 推論算力，為微型邊緣端提供了強大的性能基礎。

3.3. 結構性瓶頸：四大阻礙

在 Senior Research Consultant 的視角下，邊緣部署面臨的並非單一挑戰，而是系統性的架構瓶頸 (Architectural bottlenecks)，包含：算力牆、記憶體牆、能耗牆與通訊牆。其中「記憶體牆」尤為致命，由於 Transformer 模型的權重規模往往超出單晶片 SRAM 容量，如何優化記憶體存取成為模型部署的關鍵。

4. 開發流程自動化：Edge Impulse 與主流工具鏈分析

標準化的開發流程是降低 AI 落地門檻的關鍵。Edge AI 開發涵蓋七大循環步驟：資料收集、資料標註、模型建置、訓練調參、模型優化、部署測試及結果後處理。

4.1 主流工具鏈競爭態勢

- Edge Impulse Studio：擁有最完整的專案功能表，包含 EON Tuner 模型優化與 Performance calibration 效能校正。
- SenseCraft AI (Seeed Studio)：強調快速部署，支援 Himax WE2 等主流硬體。
- Roboflow：影像類 AI 的首選，擁有強大的雲端標註功能與巨量資料集。

4.3 技術鏈整合：以 Himax WE2 為例

從在 TinyML 實作流程中，各工具間的橋接至關重要。以 Himax WE2 (Cortex-M55 + Ethos-U55) 為例：開發者在 Roboflow 定義目標並獲取資料，匯入 Edge Impulse 進行訓練並導出 `model.tflite`。關鍵步驟在於使用 Vela Compiler，將通用的 TensorFlow Lite 模型編譯為針對 NPU 最佳化的 `model.vela.tflite`，這才是實現硬體加速推論的核心環節。

5. 台灣半導體生態系與產業戰略觀察

台灣在全球 Edge AI 供應鏈中具備極高的垂直整合戰略地位：

- **奇景光電 (Himax)**：HX6538 (WE2) 具備強大的感知處理能力。
- **新唐 (Nuvoton)**：M55M1 系列憑藉 110 GOP 的推論實力，領先同級 MCU。
- **瑞昱 (Realtek)**：RTL8735B 提供 0.4 TOPS 算力，支援高階影像編碼。
- **阿比特 (Upbeat)**：專注於 RISC-V 架構 SoC 的靈活開發。

5.1. 併購趨勢與戰略必要性

產業格局正快速整合。Qualcomm (高通) 於 2025 年 3 月與 10 月先後併購 Edge Impulse 與 Arduino。這種「生態鎖定 (Ecosystem Lock-in)」趨勢使得開發台版自主平台不再只是願景，而是確保台灣晶片業者技術自主與市場競爭力的戰略必要性。

5.2. 在地化研發優勢

台灣在自動化工具鏈上的實力已初見成效。郭峻因教授提出的 eAI-Craft 解決方案展現了 100 倍的標註效率與 90% 的模型壓縮率。這種在地 R&D 強度，結合新唐與工研院合作的 TinyML 微型運算平台，將成為台版平台對抗國際巨頭的核心競爭力。

6. 研究生視角的省思與結論

對於資工領域研究生而言，TinyML 的研究價值在於其對軟硬體協同設計 (Co-design) 的極致要求。

具體研究反思方向：

1. **極低功耗下的數值優化**：在記憶體受限下，如何透過量化 (Quantization) 技術，將模型精度從 FP32 壓低至 INT8, FP8, 甚至是 FP4，同時維持推論準確度。
2. **編譯器優化的挑戰**：面對不同 NPU 的專用指令集，Vela Compiler 等編譯器的自動化優化深度，將直接決定硬體效能的發揮上限。
3. **開源工具的槓桿效應**：研究者應善用 GitHub 上的開源資源。例如 uTensor (擁有 1.9k stars)，其針對 Mbed 平台的 C++ 庫生成能力，是論文實驗轉化為實體專案的最佳加速器。

從雲端到邊緣的轉型是未來十年的必然趨勢。研究生應積極掌握從資料鏈結、模型量化到 Vela Compiler 編譯的全棧技能。透過整合台灣既有的硬體算力優勢與如 eAI-Craft 之類的自動化工具，我們將能建立一套自主可控的邊緣 AI 生態系，在「Agentic AI」時代佔據關鍵生態位。