

2026/04/28 書報討論演講報告：

A Lightweight-Embedded Open-Set Speaker Identification System Based on Meta Learning

(具冒充者與欺騙攻擊偵測之語者辨識技術深究)

演講者：國立雲林科技大學資訊工程系 許正欣副教授

1. 演講背景與核心議題概述

在當前生成式人工智慧（Generative AI）技術與 Deepfake 語音合成迅速更迭的時代，生物識別安全（Biometric Security）正面臨前所未有的挑戰。許教授本次演講聚焦於「語者辨識（Speaker Recognition）」技術，並深入探討針對「冒充者（Imposters）」與「欺騙攻擊（Spoofing Attacks）」的縱深防禦策略。

語者辨識技術主要分為兩大類型：語者驗證（Speaker Verification, 1:1）語者識別（Speaker Identification, 1:N）。其核心任務在於透過分析說話者的語音特徵來確認身分。然而，一個具備強健性的系統不僅要能識別「註冊語者（Enroll speaker）」，更必須在複雜的威脅模型下，有效過濾非註冊語者（Unregistered speakers）假造聲音（Fake speech）。

在 AI 偽造音訊足以亂真的現狀下，區分「真聲（Real）」與「假聲（Spoof）」已成為語者辨識系統生存的先決條件。若系統無法在前端有效偵測欺騙攻擊，後端的身分比對精度再高也無用武之地。這場演講的核心價值，在於其提出了一套結合信號處理與機器學習的雙階段序列防禦架構，為生物識別安全提供了工程實踐上的技術指導。

2. 欺騙攻擊（Spoofing Attacks）之多維度威脅分析

建立防禦機制的第一步是透徹了解攻擊者的手段。許教授將欺騙攻擊定義為以人為假造的聲音對系統進行非法存取，主要分為四種類型：人聲模仿（Impersonation）、錄音回放（Replay）、語音合成（Speech synthesis）與語音轉換（Voice conversion）。

為了精確部署防禦措施，我們必須依據攻擊路徑將其分類：

攻擊路徑	定義	範例
物理性訪問 (Physical Access)	透過麥克風等硬體傳感器進行的外部攻擊。	錄音回放 (Replay)
邏輯性訪問 (Logical Access)	繞過麥克風，直接向系統內部注入數位訊號流。	語音合成、 語音轉換

邏輯性訪問對傳統基於聲學環境建模的辨識模型構成了致命挑戰。由於這類攻擊直接作用於數位層面，傳統用於過濾環境噪音或分析空間餘響的算法往往失效。這要求我們必須從語音信號的「微觀特徵」中尋找合成痕跡，而非僅依賴宏觀的語音品質。

3. 系統架構：偵測與辨識的雙重防禦鏈

演講中提出的研究核心在於一個序列整合 (Serial) 的防禦架構。這種設計體現了資訊安全中的「最小授權」邏輯，確保只有通過第一道關口 (真實性) 的樣本，才能進入第二道關口 (身分比對)。

- **第一階段：偵測攻擊階段 (Spoofing Detection)**
 核心目標：二元分類判別輸入語音為 Real (真聲) 或 Spoof (假造)。
 關鍵技術：採用具備 60 維度的 CQCC 特徵，配合深度神經網路進行偵測。
- **第二階段：語者辨識階段 (Speaker Recognition)**
 核心目標：在確定為真聲後，進一步比對該語音是否屬於特定註冊用戶。
 關鍵技術：提取 MFCC 與 i-vector 特徵，並透過整體學習 (Ensemble Learning) 模型進行決策。

這種「先偵測、後辨識」的架構能有效避免系統在處理惡意樣本時浪費過多的運算資源於身分比對，同時確保了辨識模型是在「已知為真」的前提下運作，大幅降低了誤授權的風險。

4. 關鍵技術解析：從 CQCC 特徵到 i-vector 建模

理解特徵擷取 (Feature Extraction) 的本質至關重要。演講中深入比較了兩套針對不同任務設計的特徵體系。

4.1 CQCC (Constant Q Cepstral Coefficients)

CQCC 是偵測欺騙攻擊的利器，維度設定為 60。相對於傳統 FFT，它基於 CQT 轉換，具備以下優勢：

- **對數標度 (Log scale)**：頻率軸非線性分布，與人類聽覺系統的感知模型更

一致。

- **變動長度窗口**：高頻解析度與低頻細節的動態平衡，使其對語音合成中產生的細微非自然特徵（Artifacts）高度敏感。
- **防禦導向**：CQCC 專注於捕捉合成訊號中的物理不連續性與數位痕跡（Artifact-oriented）。

4.2 i-vector 與 Total Variability

在辨識階段，需將變動長度的語音轉化為 400 維固定長度向量。其數學核心如下：

$$M=m+T\times w$$

- M ：語者 Supervector。
- m ：通用背景模型（UBM）之 Supervector。
- T ：總變異矩陣（Total Variability Matrix），係透過 UBM 語料庫 估算而得的低秩（Low Rank）矩陣。
- w ：語者對應之 i-vector，用於捕捉身分本質（Identity-oriented）。

CQCC 與 i-vector 展現了極佳的技術互補性：前者用於偵測「非自然的人工痕跡」，後者則致力於提取「語者特有的生物特徵」。

5. 模型決策邏輯：整體學習與條件式重試機制

單一模型（如 SVM 或 DNN）在邊界決策上常有局限，許教授提出透過「團隊合作」機制來強化決策嚴謹性。

- **整體學習 (Ensemble Learning)**：整合 Linear SVM、Kernel SVM、Random Forest 與 DNN。採用最嚴格的全數決（Unanimity voting）策略：必須所有分類器一致同意為真聲，方可通過。
- **條件式重試 (Conditional Retry)**：全數決雖提升安全性，卻易導致「錯誤拒絕 (False rejection)」。為平衡使用者體驗，系統引入重試機制：當語者被拒絕時，在滿足特定閾值條件下，允許 1~2 次重新辨識機會。

全數決提升了安全性上限，而條件式重試則拉高了系統的可用性下限。這種動態平衡是技術走向商業工程應用時的關鍵考量。

6. 實驗數據評估與效能分析

實驗採用 ASVspoof-2019 LA (Logical Access) 語料庫進行。該研究在模型與

特徵的選擇上進行了嚴謹的比對。

6.1. 欺騙偵測模型效能對比 (使用 CQCC 特徵)

分類器	正確率 (ACC)	偽陽率 (FPR)	真陽率 (TPR)
Linear-SVM	83.3%	18.4%	85.1%
RBF-SVM	90.0%	16.5%	97.0%
Single-model DNN	91.6%	10.8%	94.2%

6.2. 實驗發現與分析

1. **特徵優勢：**CQCC 的 ACC (91.6%) 遠優於 i-vector (75.3%) 與 MFCC (71.0%)，驗證了 CQT 轉換在偵測數位合成痕跡上的卓越性。
2. **模型架構：**採用的 DNN 架構為輸入層 9000(60 維*150 格)、隱藏層 [32, 16, 8, 1]，並使用 Adam 優化器與 Binary Cross-Entropy 損失函數。
3. **特徵降維實驗：**雖然嘗試了 PCA 與 LDA 進行特徵降維，但實驗顯示原始 9000 維特徵的通過率最佳 (Real 96.6% / Spoof 14.3%)，顯示高維特徵中仍保有關鍵的判別資訊。
4. **靜音處理之啟發：**實驗證明「靜音保留」的正確率 (91.6%) 高於「靜音移除」(86.8%)。

靜音保留的重要性在於，合成語音在「音素間靜音 (Inter-phonetic silence)」往往缺乏自然人的氣息流動感，或帶有特定的數位底噪。盲目套用傳統語音辨識的預處理 (如 VAD) 反而會抹除這些關鍵的攻擊線索。

7. 嵌入式實現與未來研究方向

許教授的研究不僅限於理論，更在 Nvidia Jetson TX2 嵌入式平台上成功實現，這對於智慧門禁等邊緣運算設備具有重大意義。

7.1. 未來研究方向

1. **引入 RNN 結構：**解決語音輸入長度不一的問題，提升時序特徵的建模能力。
2. **優化整體學習超參數：**進一步降低運算複雜度 (Computational Complexity)，以符合實時推理 (Real-time Inference) 的需求。

7.2. 研究生視角與反思

此專題給予我兩大啟發：首先，安全防禦是動態對抗的過程，防禦特徵必須具備針對性 (如 CQCC 針對人工痕跡)。其次，在邊緣裝置實現時，必須嚴謹評估模型的參數量 (如參數數量從 81M 到 129M 的效能與大小折衷)。